

MVP - Análise de Eficiência e Custos das Internações Hospitalares no RS (SIH/DATASUS)

Repositório da entrega final do projeto de engenharia e análise de dados focado no Sistema de Informações Hospitalares do SUS (SIH/SUS), processado por meio da arquitetura Medallion no Databricks com Unity Catalog.

1. Contexto de Negócios e Perguntas

O projeto visa analisar dados de internações hospitalares financiadas pelo SUS no Estado do Rio Grande do Sul (RS), com foco em diagnósticos de alta criticidade (Neoplasias, Afecções Cardíacas, Respiratórias e Renais) e custos associados, visando subsidiar a tomada de decisão e o planejamento em operadoras de plano de saúde.

Por trabalhar em uma operadora de planos de saúde, que também necessita da análise de dados da saúde pública para guiar suas decisões, optei por realizar essa análise das internações no estado do Rio Grande do Sul.

Perguntas de Negócio (Etapas 2 e 4.1)

- 1. Quais são as patologias (CID) e procedimentos que concentram o maior custo total e maior valor médio por internação?*
- 2. Qual é o tempo médio de permanência (dias em leito) por especialidade médica e faixa etária?*
- 3. Qual é a taxa de mortalidade hospitalar cruzada por caráter de atendimento (Eletivo vs. Urgência/Emergência) e faixa etária?*
- 4. Existe variação significativa no custo médio por internação entre os diferentes municípios e/ou regiões do RS?*

Estrutura dos Dados Brutos:

Dados tabulares extraídos de bases públicas/Kaggle contendo registros detalhados de internações (competências do SIH/SUS), com dados abrangendo de 2008 a 2023 e a tabela de subcategorias da CID-10.

Licença dos Dados: Dados públicos abertos disponibilizados sob termos de uso governamentais e de domínio público para fins educacionais, de pesquisa e transparência pública.

2. Carga dos Dados (Etapa 4.2)

Os arquivos brutos foram ingeridos e persistidos inicialmente na camada Bronze ('mvp_saude.default') no Databricks. O processo envolveu a leitura das bases em formato tabular/CSV e estruturação inicial.

O código de ingestão e estruturação inicial da camada Bronze está localizado no Databricks Workspace em:

`/Users/maridepaoli@gmail.com/MVP_Saude_DATASUS/MVP03_Bronze`

3. Modelagem e Catálogo de Dados (Etapa 4.3)

Modelagem: Implementação de um Modelo Estrela (*Star Schema*) contendo a tabela fato de internações (`sih\_cleaned`) e dimensões normalizadas na camada Silver (`dim\_cid10`, `dim\_municipios`, `dim\_especialidades`), evoluindo para tabelas analíticas agregadas na camada Gold.

Catálogo de Dados: As tabelas e colunas foram documentadas nativamente utilizando os comandos de metadados do Unity Catalog (`COMMENT ON`).

Camada / Schema | Tabela | Descrição Principal |

Silver: `mvp\_saude.silver.dim\_cid10` | Dimensão padronizada e limpa da CID-10 (Chave primária).

Silver: `mvp\_saude.silver.dim\_municipios` | Dimensão de municípios geográficos do RS.

Silver: `mvp\_saude.silver.dim\_especialidades` | Dimensão de especialidades médicas/leitos.


Silver: `mvp\_saude.silver.sih\_cleaned` | Fato intermediária de internações limpa e tipada.

Gold: `mvp\_saude.gold.gold\_resumo\_geral\_rs` | Visão macro contendo o resumo geral dos indicadores de saúde e custos do estado.

Gold: `mvp\_saude.gold.gold\_internacoes\_por\_diagnostico` | Agregações de internações agrupadas por CID-10, custos, permanência e mortalidade.

Gold: `mvp\_saude.gold.gold\_internacoes\_por\_municipio` | Agregação analítica por município mapeando a distribuição dos atendimentos e gastos no RS.

Gold: `mvp\_saude.gold.gold\_custo\_medio\_por\_regiao` | Consolidação de custos totais, custos médios por internação e mortalidade por macrorregiões de saúde.



4. Pipeline de Dados (Etapa 4.4)

Organização do Pipeline (ETL): O pipeline foi estruturado de forma modularizada seguindo a arquitetura Medallion em notebooks separados por camadas:

1. Bronze (`MVP03\_Bronze`): Ingestão bruta dos dados originais.


2. Silver (`MVP04\_Silver`): Limpeza, tipagem, tratamento de nulos, resoluções de codificação e unificação com chave única (`groupBy` + `first`).
3. Gold (`MVP05\_Gold`): Cruzamentos relacionais (`JOIN`) e agregações analíticas para responder às perguntas de negócio.

Scripts no GitHub: Disponibilizados no repositório público

github.com/maridepaoli-dev/MVP_Saude

Persistência na Nuvem: As tabelas utilizam o formato Delta Lake gerenciado pelo Databricks Unity Catalog.

Lineage for mvp_saude.silver.dim_cid10



5. Qualidade de Dados (Etapa 4.5)

Problemas Detectados:

- Duplicidade de chaves primárias na dimensão de CIDs, gerando instabilidade e oscilação nos totais das análises;
- Estrutura original da base pública baseada puramente em **códigos desnormalizados** (tanto para diagnósticos via CID-10 quanto para a localização geográfica de municípios), sem os descritivos textuais legíveis para relatórios executivos.

Transformações e Resoluções:

- Aplicação de rigorosa garantia de unicidade de chave primária na `dim_cid10` utilizando `groupBy("cod_cid_principal")` com agregação `agg(F.first(...))` para congelar o comportamento determinístico da base;
- Enriquecimento e Tradução de Códigos: Implementação de tabelas dimensionais de apoio (`dim_municipios` e `dim_cid10`) para traduzir os códigos brutos da base em descrições textuais legíveis:
 - **Municípios (`dim_municipios`):** Integração direta com a **API de Localidades do IBGE** ([\[https://servicodados.ibge.gov.br/api/v1/localidades/estados/43/municipios\]](https://servicodados.ibge.gov.br/api/v1/localidades/estados/43/municipios)) (<https://servicodados.ibge.gov.br/api/>

v1/localidades/estados/43/municipios)), garantindo o mapeamento exato entre os códigos IBGE e os nomes oficiais das cidades do Estado do Rio Grande do Sul (UF 43).

- **Diagnósticos (dim_cid10):** Acoplamento da tabela de referência de subcategorias da CID-10 (cid_10_subcategorias), padronizando o código médico com a sua respectiva descrição patológica sem inconsistências.

6. Análise de Dados (Etapa 4.5)

A partir do consumo das tabelas consolidadas na camada Gold:

gold_resumo_geral_rs,

gold_custo_medio_por_regiao,

gold_internacoes_por_diagnostico,


gold_internacoes_por_municipio e

mvp_saude.gold.gold_custo_medio_por_regiao, foi realizada a exploração

analítica para responder de forma direta às diretrizes levantadas na etapa de planejamento (4.1):

1. Quais são as patologias (CID-10) e procedimentos que concentram o maior custo total e maior valor médio por internação?


- *Resposta analítica:* Mapeada por meio da tabela gold_internacoes_por_diagnostico, que correlaciona o código e a descrição da patologia (via dim_cid10) com o custo financeiro acumulado (custo_total_cid) e o impacto unitário (custo_medio_internacao), destacando quais morbidades mais oneram o sistema público de saúde no RS.



	A ^B C descricao_cid	A ^B C total_internacoes	A ^B C custo_total	A ^B C valor_medio_internacao
1	Insuficiencia respiratoria cronica	17	566.447,00	33.320,41
2	Flutter e fibrilacao ventricular	22	547.896,36	24.904,38
3	Aneurisma da aorta toracica	16	339.289,74	21.205,61
4	Tetralogia de Fallot	5	98.660,27	19.732,05
5	Comunicacao interventricular	7	136.257,99	19.465,43
6	Aneurisma de arteria iliaca	7	131.918,83	18.845,55
7	Aneurisma da aorta abdominal	20	356.251,45	17.812,57
8	Insuficiencia (da valva) mitral	10	169.341,95	16.934,19
9	Outras formas de cirrose hepatica e as nao especificad...	75	1.190.555,62	15.874,07
10	Insuficiencia hepatica	16	248.532,95	15.533,31


2. Qual é o tempo médio de permanência (dias em leito) por especialidade médica e faixa etária?

- *Resposta analítica:* Extraída a partir do cruzamento de dimensões e fatos tratadas na camada Silver (`sih_cleaned` e `dim_especialidades`), permitindo dimensionar a retenção hospitalar e a eficiência do uso de leitos por perfil demográfico e especialidade médica.




3. Qual é a taxa de mortalidade hospitalar cruzada por caráter de atendimento (Eletivo vs. Urgência/Emergência) e faixa etária?


Resposta analítica: Respondida mediante agregações de desfecho e morbidade na camada Gold, cruzando o volume de óbitos com o total de internações para avaliar o risco clínico conforme a urgência do acesso e a idade do paciente.



4. Existe variação significativa no custo médio por internação entre os diferentes municípios e/ou regiões do RS?

- *Resposta analítica:* Respondida através das tabelas [gold_custo_medio_por_regiao](#) e [gold_internacoes_por_municipio](#) (enriquecidas com a API de municípios do IBGE), evidenciando as assimetrias regionais e os custos médios praticados nas diferentes macrorregiões de saúde do estado.





7. Autoavaliação

Atingimento de Objetivos: Os objetivos delineados no início do projeto foram plenamente atingidos, conseguindo responder às perguntas elencadas no início do trabalho.

Dificuldades Encontradas: O maior desafio técnico consistiu no tratamento dos dados e duplicidades das bases públicas do SUS, superado através da criação de um dicionário de equivalência de chaves exatas e importação de tabelas para auxiliar na classificação dos CID's e cidades.

Trabalhos Futuros:

- Integrar os dados da camada Gold a uma ferramenta de BI (como Power BI ou Tableau) para elaboração dashboards interativos que auxiliem nas tomadas de decisões
- Realizar a mesma análise com dados de uma operadora de saúde para fins comparativos com o SUS.